



# Clasificarea semnalelor ECG utilizand Retele Neuronale Convolutionale

**AUTOR:ILINCA ANDREI-ALEXANDRU, ANUL I, GRUPA 312AA**

**COORDONATOR:S.L. DR. ING. POPESCU DRAGOS CONSTANTIN**



# Cuprins:

1.Introducere.....	3
2.Motivatie.....	4
3.Rezumat.....	5
4.Electrocardiograma.....	6
5.Setul de date.....	7
6.Zgomotul din semnalele ECG.....	8
7.Transformata Wavelet.....	9
8.Prelucrarea semnalelor.. ..	10
9.Reteaua Neuronala Convolutionala.....	12
10.Rezultate.....	14
11.Bibliografie.....	15



# 1.Introducere:

Intre anii 1990 si 2021 rata deceslor provocate de afectiuni cardiovasculare a crescut semnificativ de la 12.1 milioane(1990) la 20.5 milioane(2021), in 2021 fiind cauza principala de deces la nivel mondial conform World Heart Federation(WHF)[\[1\]](#).

Utilizand electrocardiografe, afectiunile cardiovasculare pot fi depistate la timp pentru ca efectul lor sa fie remediat.

Cuvinte cheie: electrocardiograma, wavelets, retele neuronale convolutionale



## 2.Motivatie:

- Studierea tehnicilor de invatare supervizata bazate pe retele neuronale convolutionale.
- Studierea metodelor de analiza si prelucrare a semnalelor bio-medicale.
- Utilizarea proiectului ,dar si a cunostiintelor dobandite, in alte proiecte viitoare.


---

## 3.Rezumat:

- Scop: clasificarea semnalelor de electrocardiograma in 55 de clase.
- Prin utilizarea anumitor tehnici de analiza a semnalelor bazate pe filtrarea frecventelor si a retelelor neuronale convolutionale s-a reusit clasificarea semnalelor ECG in cele 55 de clase propuse in setul de date colectat.

## 4. Electrocardiograma

- O electrocardiograma reprezinta inregistrarea impulsurilor electrice produse de musculatura inimii.
- Unda P-depolarizarea artiala
- Segmentul PR-intervalul intre undele P si Q. Reflecta timpul necesar pentru ca impulsul electric sa calaoreasca de la nodul sinusal prin atrii pana la nodul atrioventricular
- Unda Q-depolarizarea primara a ventriculelor
- Unda R-continuitatea depolarizarii ventriculare
- Unda S-delexiunea negativa urmata de unda Rpai
- Segmentul ST-perioada de timp intre depolarizarea si repolarizarea ventriculelor
- Unda T-repolarizarea ventriculelor
- Segmentul TP-perioada de repaus electric intre doua cicluri cardiace




unda electrocardiograma

Fig. 1

## 5.Setul de date:

- Creat de catre Chapman University(California), Shaoxing People's Hospital si Ningbo First Hospital setul de date contine ECG-uri cu 12 derivatii colectate cu o rata de esantionare de 500 de Hz de la 45152 de pacienti.



Exemplu derivatie semnal ECG din setul de date

Fig. 2



## 6. Zgomotul in semnalele ECG:

- Zgomotul este rezultatul a mai multi factori:
  - zgomot electric ambiental: produs din surse externe, echipamente, linii de alimentare
  - zgomot produs de contactul electrozilor cu pacientul: miscarea pacientului, respiratia, contactul electrozilor cu pielea



## 7.Transformata Wavelet:

- Se definește transformata Wavelet continuă a unei funcții  $f$  la un moment de timp  $u$  și scală  $s$  ca fiind [2]:

$$W_f(u,s) := \int_{-\infty}^{\infty} f(t) \Psi_{u,s}^*(t) dt \quad (1)$$

$$\Psi_{u,s}(t) := \frac{1}{\sqrt{s}} \Psi\left(\frac{t-u}{s}\right), u \in \mathbb{R}, s > 0$$

$\Psi_{u,s}^*$  conjugată complexă a  $\Psi_{u,s}$

$\Psi$  – funcție Wavelet

$$\Psi \in L^2(\mathbb{R})$$

$$\int_{\mathbb{R}} \Psi = 0$$

## 8. Prelucrarea semnalelor:

- Semnalele au fost filtrate folosind un filtru butterworth lowpass cu frecventa de taiere de 20Hz pentru a reduce zgomotul[3].

$$|H(j\Omega)| = \frac{1}{\sqrt{1 + \left(\frac{\Omega}{\Omega_c}\right)^{2N}}} \quad (2)$$

$\Omega_c$ -frecventa de prag  
N-ordin  
H- functia de transfer

- metoda propusa in articolul [4] a fost utilizata pentru a reduce linia de baza prin descompunerea semnalului folosind transformata Wavelet.

-pentru fiecare nivel de scala se calculeaza energia semnalului corespunzatoare segmentului de detalii folosind coeficientii Wavelet.

$$W_f(j, k) = \sum_n f(n) \Psi_{j,k}(n) \quad (3)$$

$$E(j) = \sum_k |D(j, k)|^2 \quad (4)$$

E-energia semnalului

D-coeficientii de scala

-se utilizeaza coeficientii de aproximare pentru a reconstrui linia de baza

$$x(n) = \sum_k D(j, k) \Phi_{j,k}(n) \quad (5)$$


$\Phi_{j,k}(n)$  – functia de scalare

-se identifica nivelul de scala la care energia semnalului corespunzator coeficientului de detalii atinge un minim local.


-se scade din semnalul initial linia de baza obtinuta

- Semnalele filtrate au fost convertite la scalograme folosind Wavelet-ul Gaussian

$$\Psi(x) = xe^{-\frac{x^2}{2}} \quad (6)$$




Wavelet Gaussian  
Fig. 4



Exemplu scalograma  
Fig.3

## 9. Reteaua Neuronala Convolutionala:

- Antrenamentul a fost bazat pe invatare prin transfer pornindu-se de la modelul Alex Net cu ultimul strat modificat pentru a permite clasificarea in 55 de clase..



Arhitectura AlexNet[6]

Fig.5

- S-a utilizat biblioteca PyTorch pentru implementarea modelului.
- Antrenare facuta pe o epoca pe un set de date de 5634 de scalograme.
- Testare facuta pe 2485 de scalograme.
- Functia de activare utilizata este ReLU:

$$ReLU(x) = \max(0, x) \quad (7)$$

- Functia de pierdere utilizata este Pierdere entropica incrucisata binara cu logituri[7]:

$$l_n = -w_n[y_n \log(\sigma(x_n)) + (1 - y_n) \log(1 - \sigma(x_n))] \quad (8)$$

$x_n$  – *predictia modelului*

$y_n$  – *eticheta adevarata*

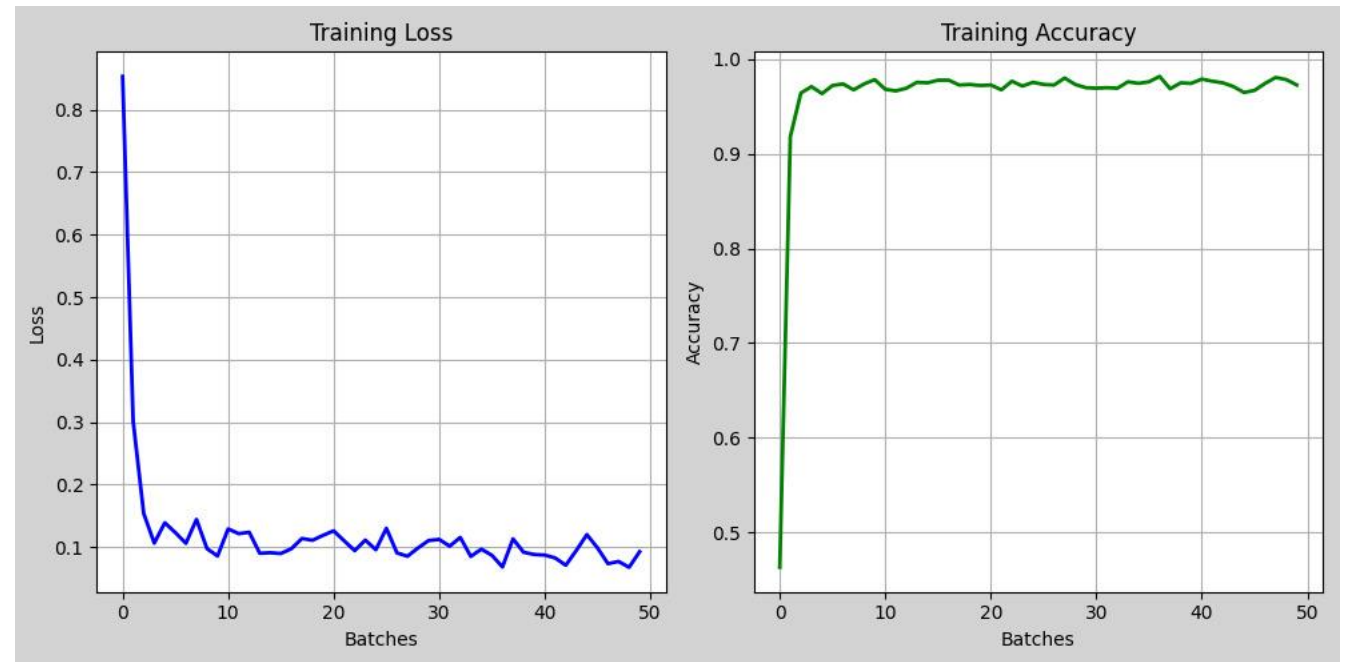
$w_n$  – *factor de ponderare*

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

# 10.Rezultate:

```
Batch number: 172, Training: Loss: 0.0637, Accuracy: 0.9790
Batch number: 173, Training: Loss: 0.0749, Accuracy: 0.9778
Batch number: 174, Training: Loss: 0.0624, Accuracy: 0.9818
Batch number: 175, Training: Loss: 0.0563, Accuracy: 0.9818
Batch number: 176, Training: Loss: 0.1200, Accuracy: 0.9636
Acuratete medie: 0.994556429486007
```

Rezultat antrenament  
Fig.6



Funcția de cost și acurătatea  
Fig.7

# 11. Bibliografie:

- [1]:<https://world-heart-federation.org/news/deaths-from-cardiovascular-disease-surged-60-globally-over-the-last-30-years-report/>
- [2]Bolós, Vicente J., and Rafael Benítez. "The wavelet scalogram in the study of time series." *Advances in Differential Equations and Applications*. Cham: Springer International Publishing, 2014. 147-154.
- [3] Butterworth, Stephen. "On the theory of filter amplifiers." *Wireless Engineer* 7.6 (1930): 536-541.
- [4]:A. Sargolzaei, K. Faez and S. Sargolzaei, "A new robust wavelet based algorithm for baseline wandering cancellation in ECG signals," 2009 IEEE International Conference on Signal and Image Processing Applications, Kuala Lumpur, Malaysia, 2009, pp. 33-38, doi: 10.1109/ICSIPA.2009.5478671. keywords: {Robustness;Electrocardiography;Wavelet analysis;Discrete wavelet transforms;Wavelet transforms;Databases;Digital filters;Time frequency analysis;Signal processing;Signal analysis;Baseline Wandering;Electrocardiogram;Wavelet Transform},
- [5] Alex, Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional networks." *volume-1; pages-1097-1105; NIPS'12 Proceedings of the 25th International Conference on Neural Information Processing System*.
- [6]<https://anhreynolds.com/blogs/alexnet.html>
- [7]<https://pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>
- Setul de date: <https://physionet.org/content/ecg-arrhythmia/1.0.0/>
- Yoon, T., Kang, D. Bimodal CNN for cardiovascular disease classification by co-training ECG grayscale images and scalograms. *Sci Rep* 13, 2937 (2023)
- Aqil, Mounaim, Atman Jbari, and Abdennasser Bourouhou. "ECG Signal Denoising by Discrete Wavelet Transform." *International journal of online engineering* 13.9 (2017).
- Aziz, Saira, Sajid Ahmed, and Mohamed-Slim Alouini. "ECG-based machine-learning algorithms for heartbeat classification." *Scientific reports* 11.1 (2021): 18738.